

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ
БЮДЖЕТНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«ФИНАНСОВЫЙ УНИВЕРСИТЕТ ПРИ ПРАВИТЕЛЬСТВЕ
РОССИЙСКОЙ ФЕДЕРАЦИИ»
(ФИНАНСОВЫЙ УНИВЕРСИТЕТ)

Кафедра искусственного интеллекта
Факультета информационных технологий и анализа больших данных

Дисциплина: «Прикладные задачи машинного обучения»
Направление подготовки: «Прикладная математика и информатика»
Профиль: «Прикладное машинное обучение»
Факультет информационных технологий и анализа больших данных
Форма обучения очная
Учебный 2025/2026 год, 7 семестр

Курсовая работа на тему:

«Разработка нейронной сети для распознавания эмоций в текстах и их
применения в маркетинге»

Выполнила:

студентка группы ПМ22-6

Маслакова Анастасия Витальевна

Научный руководитель:

доцент Маковейчук Кристина Александровна

Москва 2025

Оглавление

Введение.....	3
1. Анализ данных и постановка задачи.....	4
1.1. Анализ эмоций в тексте и его особенности.....	4
1.2. Характеристика набора данных.....	5
1.3. Первичный анализ данных.....	6
1.4. Предобработка данных.....	9
1.5. Постановка задачи и метрики качества	10
2. Реализация моделей	10
2.1. Разделение данных.....	10
2.2. Базовая модель	11
2.3. Нейросетевая модель	12
2.3.1. Подготовка к обучению нейронной сети	13
2.3.2. Архитектура нейронной сети	13
2.3.3. Подбор гиперпараметров	14
2.3.4. Обучение нейронной сети.....	14
2.4. Финальная оценка модели.....	14
3. Применение модели распознавания эмоций в маркетинге.....	17
3.1. Data-driven marketing	17
3.2. Распознавание эмоций как инструмент анализа потребительского поведения	18
3.3. Основные области применения моделей распознавания эмоций	19
Заключение	20
Список литературы	21
Приложение	23

Введение

Цифровые технологии постоянно развиваются и улучшаются. Благодаря этому в последние годы количество текстовой информации в интернете увеличилось в разы. Эта информация включает в себя не только статьи, книги или блоги, но и комментарии людей в социальных сетях и отзывы о продуктах или услугах. Эти данные отражают мнения и эмоции людей и очень важны для изучения поведения пользователей, чтобы потом применять их в разработке маркетинговых стратегий. В условиях растущей конкуренции компании вынуждены искать новые инструменты для автоматического определения эмоционального окраса текстовых данных.

Распознавание эмоций в тексте – это одно из направлений NLP или обработки естественного языка. Основная его особенность состоит в том, что классификатор должен более глубоко понимать чувства, скрытые в тексте по сравнению с, например, простым определением тональности. Используя машинное обучение и нейронные сети можно построить модель эмоциональной классификации способную учитывать контекст и смысловые связи между словами.

Актуальность данного исследования обусловлена тем, что компаниям необходимо анализировать эмоциональную реакцию своих клиентов на продукт, чтобы впоследствии улучшать качество товара, рекламу и обслуживание. Автоматизация этого процесса позволит повысить точность анализа и маркетинговых решений.

Цель работы: разработка нейронной сети для распознавания эмоций в текстах и анализ ее практического применения в маркетинге.

Задачи:

1. Анализ предметной области;
2. Исследование датасета и предобработка текстовых данных;
3. Постановка задачи машинного обучения и определение целевых метрик качества;
4. Реализация базовой модели и нейронной сети, их обучение и оптимизация;

5. Интерпретация результата;
6. Анализ практических сценариев применения разработанной модели в маркетинге.

1. Анализ данных и постановка задачи

1.1. Анализ эмоций в тексте и его особенности

Анализ эмоций в тексте (sentiment analysis, emotion analysis) является одной из ключевых задач обработки естественного языка (Natural Language Processing, NLP). Его целью является автоматическое определение эмоциональной окраски текстовой информации, а также выявление конкретных эмоциональных состояний, выраженных автором, таких как радость, грусть, гнев, страх или нейтральное состояние.

В отличие от обычного анализа тональности, который определяет, положительный, отрицательный или нейтральный текст, анализ эмоций дает более подробное представление об эмоциональной окраске текста. Это усложняет задачу, поскольку эмоции могут быть выражены скрыто и зависят от контекста, лексики и даже культуры. К тому же, в одном тексте может быть несколько эмоций сразу.

Особенностью анализа эмоций является разнообразие языковых выражений, наличие иронии, сарказма и метафор, а также зависимость от контекста. Для решения этой задачи применяются методы машинного обучения со словарями эмоций, составленными вручную, а также современные нейросети, такие как LSTM, BiLSTM и трансформеры, которые учитывают контекст и порядок слов¹.

¹ Жан Макс Тапе Хабиб, Алексей Андреевич Погуда Сравнение методов анализа настроений глубокого обучения, включая LSTM и машинное обучение // Открытое образование. 2023. №4. URL: <https://cyberleninka.ru/article/n/sravnenie-metodov-analiza-nastroeniy-glubokogo-obucheniya-vklyuchaya-lstm-i-mashinnoe-obuchenie> (дата обращения: 16.12.2025).

Анализ эмоций активно применяется в разных областях, включая анализ отзывов, мониторинг соцсетей, оценку общественного мнения и системы поддержки принятия решений.

1.2. Характеристика набора данных

В работе для решения задачи анализа эмоций в текстах используется открытый датасет, размещённый на Kaggle². Набор данных представляет собой текстовые сообщения, размеченные по типам эмоций, выражаемых в них.

Датасет содержит 416 809 текстовых наблюдений, каждое из которых состоит из двух признаков: текстового сообщения (text) и числовой метки эмоции (label) (см. Таб. 1). Тип данных текстового поля - строковый, а метки эмоций представлены целочисленными значениями. Пропущенные значения в наборе данных отсутствуют.

Таблица 1 - Фрагмент датасета

	text	label	Emotion
0	i just feel really helpless and heavy hearted	4	fear
1	ive enjoyed being able to slouch about relax a...	0	sadness
2	i gave up my internship with the dmrp and am f...	4	fear
3	i dont know i feel so lost	0	sadness
4	i am a kindergarten teacher and i am thoroughl...	4	fear

В ходе предварительного анализа были выявлены 686 дублирующихся записей, которые были удалены.

Всего в наборе данных представлено шесть классов эмоций: грусть (sadness), радость (joy), любовь (love), гнев (anger), страх (fear) и удивление (surprise). В датасете присутствует явный дисбаланс (см. Рис.1), который необходимо учитывать при обучении моделей.

² Emotions // Kaggle URL: <https://www.kaggle.com/datasets/nelgiriyeewithana/emotions/data> (дата обращения: 16.12.2025).

Набор данных достаточно большой, хорошо структурирован и содержит разнообразные эмоциональные категории. Это делает его подходящим для решения задачи курсовой работы.




Рисунок 1 - Распределение классов эмоций

1.3. Первичный анализ данных

Был проведен первичный анализ данных (Exploratory Data Analysis, EDA).

Анализ распределения длины текстов показал, что большинство сообщений являются короткими и не превышают 200 символов (см. Рис. 2). Такое распределение характерно для комментариев, отзывов и сообщений в социальных сетях.




Рисунок 2 - Распределение длины текста




Рисунок 3 - Количество слов в тексте по эмоциям

связана с тем, что анализируемые тексты являются пользовательскими и ориентированы на выражение собственных эмоций.




Рисунок 5 - Топ-15 биграмм

1.4. Предобработка данных

Чтобы обучить модели, текст надо сначала привести к единому формату. Качество предобработки напрямую влияет на результат работы модели.

На данном этапе была выполнена базовая очистка текстов. Все сообщения были приведены к нижнему регистру, из текстов были удалены URL-адреса, HTML-теги и пользовательские упоминания, не несущие семантической нагрузки. В результате получили новую колонку `clean_text`, содержащая очищенные версии исходных сообщений (см. Табл. 2).

Таблица 2 - Фрагмент датасета с очищенным текстом

	text	clean_text
0	i just feel really helpless and heavy hearted	i just feel really helpless and heavy hearted
1	ive enjoyed being able to slouch about relax a...	ive enjoyed being able to slouch about relax a...
2	i gave up my internship with the dmrg and am f...	i gave up my internship with the dmrg and am f...
3	i dont know i feel so lost	i dont know i feel so lost
4	i am a kindergarten teacher and i am thoroughl...	i am a kindergarten teacher and i am thoroughl...

1.5. Постановка задачи и метрики качества

В работе рассматривается задача многоклассовой классификации текстов по эмоциональной окраске.

Для оценки качества построенной модели используются следующие метрики:

- Weighted F1-score – основная метрика. Она учитывает точность (precision) и полноту (recall) для каждого класса и взвешивает их в соответствии с размером класса. Метрика устойчива к дисбалансу классов и хорошо работает при оценке качества многоклассовой классификации.
- Ассигасу – используется в качестве вспомогательной метрики. Она позволяет оценить общую долю правильно классифицированных примеров, однако не отражает реального качества модели при наличии дисбаланса классов.
- Confusion Matrix (матрица ошибок) – применяется для визуального анализа результатов классификации.
- ROC-AUC – используется для оценки способности модели различать классы. В многоклассовом случае эта метрика рассчитывается в усреднённом виде и позволяет дополнительно оценить качество разделения классов.

2. Реализация моделей

2.1. Разделение данных

Исходный набор данных был разделён на три подмножества: обучающую, валидационную и тестовую выборки. В качестве входных данных используется очищенный текст (clean_text), а в качестве целевой переменной – числовая метка эмоции (label).

Разделение данных выполнено в соотношении 80%/10%/10% для обучающей, валидационной и тестовой выборок соответственно. Обучающая

выборка содержит 332898 наблюдений, валидационная – 41612, тестовая – 41613.

Поскольку задача является многоклассовой и имеет дисбаланс классов, разбиение выполнялось с использованием стратификации. Это позволяет сохранить пропорции классов эмоций во всех подвыборках.

2.2. Базовая модель

В качестве базовой модели в данной работе используется линейная модель метода опорных векторов (Support Vector Machine, SVM). Основная цель применения данной модели заключается в получении базового уровня качества (baseline), с которым в дальнейшем сравниваются результаты нейронной сети.

Перед обучением модели текстовые данные были преобразованы в векторы с помощью метода TF-IDF (Term Frequency – Inverse Document Frequency).

После векторизации текстов модель LinearSVC была обучена на обучающей выборке и протестирована на тестовом наборе данных.

Таблица 3 - Отчет классификации SVM-модели

	precision	recall	f1-score	support
0	0.94	0.94	0.94	12099
1	0.91	0.93	0.92	14078
2	0.81	0.79	0.80	3449
3	0.90	0.89	0.89	5724
4	0.85	0.85	0.85	4767
5	0.77	0.72	0.74	1496
accuracy			0.90	41613
macro avg	0.86	0.85	0.86	41613
weighted avg	0.90	0.90	0.90	41613




Рисунок 6 - Матрица ошибок SVM-модели

Результаты эксперимента показали, что базовая модель демонстрирует достаточно высокое качество классификации (см. Табл. 3). Значение Weighted F1-score составило 0.90, а общая точность (ассурасу) также достигла 0.90. Однако ухудшение точности для некоторых классов указывает на то, что нужны более продвинутые нейросетевые методы, которые лучше анализируют контекст и смысл текста.

2.3. Нейросетевая модель

Для улучшения качества классификации текстов была использована более сложная модель - двунаправленная рекуррентная нейронная сеть на основе LSTM (Bidirectional LSTM, BiLSTM).

2.3.1. Подготовка к обучению нейронной сети

Были рассчитаны веса классов для работы с дисбалансом классов в данных. Это позволяет более точно учитывать все категории эмоций при обучении модели.

Для работы с данными был создан класс `EmotionDataset`, который занимается токенизацией текста и подготовкой данных для загрузки в модель. Этот класс преобразует каждое сообщение в последовательность индексов слов, дополненную до фиксированной длины (максимум 200 токенов).

2.3.2. Архитектура нейронной сети

Модель основана на двунаправленной LSTM-сети³. Архитектура состоит из следующих компонентов:

- Embedding слой преобразует токены текста в векторы. Используется `padding_idx=0` для корректной обработки дополненных последовательностей.

- LSTM слой с двумя направлениями (`bidirectional=True`) и несколькими слоями (по умолчанию два). Использование нескольких слоёв помогает модели извлекать более сложные зависимости в тексте, а регуляризация с помощью `dropout` уменьшает риск переобучения.

- Pooling: для извлечения признаков из выходных данных LSTM используются две стратегии: `mean pooling` - вычисляется среднее значение по всем токенам текста, что отражает общий эмоциональный фон, `max pooling` - выделяет наиболее эмоционально насыщенные токены текста.

- Classifier состоит из:

1. Полносвязного слоя для снижения размерности признакового пространства
2. `BatchNorm` и `ReLU` для улучшения нелинейного разделения классов
3. `Dropout` для регуляризации

³ Xie, Jun and Chen, Bo and Gu, Xinglong and Liang, Fengmei and Xu, Xinying Self-Attention-Based BiLSTM Model for Short Text Fine-grained Sentiment Classification // IEEE Access. - 2019. - №7. - С. 1-1.

4. Финального Linear слоя, формирующего логиты для каждого класса эмоций

2.3.3. Подбор гиперпараметров

Для оптимизации гиперпараметров модели была использована библиотека Optuna. В ходе эксперимента были настроены следующие параметры:

- Размерность эмбедингов (embed_dim);
- Размер скрытого слоя (hidden_dim);
- Коэффициент регуляризации (dropout);
- Скорость обучения (lr).

Подбор гиперпараметров проводился с целью максимизации F1-score на валидационной выборке. После 10 попыток настройки были получены оптимальные значения гиперпараметров:

- embed_dim: 118,
- hidden_dim: 91,
- dropout: 0.64,
- lr: 0.0007.

2.3.4. Обучение нейронной сети

Для обучения модели использовался алгоритм Adam с функцией потерь кросс-энтропия, взвешенной по классам. Обучение проходило на протяжении 10 эпох, с выводом метрик train loss, val loss и F1-score для каждой эпохи.

Финальная модель, после оптимизации гиперпараметров и обучения, достигла F1-score = 0.94 на валидационной выборке, что значительно улучшает результаты базовой SVM.

2.4. Финальная оценка модели

Была проведена оценка качества обученной модели BiLSTM на тестовой выборке, которая не использовалась при обучении.

Для оценки был выведен отчет по классификации (см.Табл. 4), а также построены матрица ошибок, ROC-кривые и Precision-Recall кривые.

Таблица 4 - Отчет классификации BiLSTM-модели

	precision	recall	f1-score	support
0	1.00	0.95	0.97	12099
1	1.00	0.92	0.96	14078
2	0.78	1.00	0.87	3449
3	0.93	0.96	0.94	5724
4	0.90	0.91	0.90	4767
5	0.74	1.00	0.85	1496
accuracy			0.94	41613
macro avg	0.89	0.95	0.92	41613
weighted avg	0.95	0.94	0.94	41613

Результаты классификации показывают, что модель демонстрирует высокое качество распознавания эмоций. Accuracy = 0.94, что означает правильную классификацию 94% текстов тестовой выборки. Основная метрика работы – Weighted F1-score – также достигла значения 0.94. Значение Macro F1-score = 0.92 указывает на сбалансированное качество классификации по всем эмоциям, включая наименее представленные классы.

Анализ матрицы ошибок (см. Рис. 7) показывает, что большинство предсказаний находятся на главной диагонали, что говорит о маленьком количестве ошибок.

Также были построены ROC-кривые для каждого класса эмоций (см. Рис. 8). Значения площади под ROC-кривой (AUC) для всех эмоций находятся в диапазоне 0.996–0.999, что свидетельствует о почти идеальной способности модели различать тексты с заданной эмоцией и тексты остальных классов.




Рисунок 7 - Матрица ошибок BiLSTM-модели




Рисунок 8 - ROC-кривые BiLSTM-модели




Рисунок 9 - PR-кривые BiLSTM-модели

Также были построены Precision–Recall кривые (см. Рис. 9). В целом модель демонстрирует высокие значения средней точности (Average Precision) для всех эмоций.

Финальная модель BiLSTM продемонстрировала высокую точность и устойчивость при классификации эмоций в текстах. Полученные результаты подтверждают хорошую обобщающую способность модели и её применимость для практических задач.

3. Применение модели распознавания эмоций в маркетинге

3.1. Data-driven marketing

Маркетинг во многом опирается на data-driven подход, который предполагает глубокий анализ данных. К основным концепциям такого подхода относятся:

- Принятие решений на основе фактов;

- Глубокое понимание клиента;
- Оптимизация на каждом этапе;
- Прогнозирование и моделирование;
- Непрерывное тестирование и обучение.

Важную роль в этом играют данные. Их извлекают из всех доступных источников: социальных сетей и форумов, сайтов, писем, сообщений в службу поддержки и т.д. Все эти источники содержат не только факты о продукте или услуге, но еще и эмоциональную оценку опыта клиента. Эта оценка напрямую влияет на репутацию бренда и то, как его воспринимают.

3.2. Распознавание эмоций как инструмент анализа потребительского поведения

Использование моделей распознавания эмоций очень актуально при анализе эмоционального пути клиента – процесса понимания и влияния на то, как клиенты чувствуют себя во время взаимодействия с брендом, продуктом или услугой. В исследованиях, посвященных оптимизации цифрового клиентского пути, отмечается, что опыт формируется не отдельными действиями, а их последовательностью, где эмоции сильно влияют на восприятие и принятие решения. Изучение сообщений, отзывов, комментариев и обращений помогает определить, когда негативные эмоции растут, чтобы потом сопоставить их с этапами пути клиента: поиском информации, оформлением заказа или взаимодействием со службой поддержки.

При анализе цифровых каналов важно учитывать эмоции, чтобы точно оценить опыт клиента и выявить скрытые проблемы, которые не всегда видны или понятны при использовании только традиционных метрик, таких как конверсия или время сессии. Внедрение моделей распознавания эмоций в анализ пути клиента дает понимание факторов, которые влияют на его удовлетворенность и лояльность.

3.3. Основные области применения моделей распознавания эмоций

Первый вариант применения модели распознавания эмоций – это анализ клиентских отзывов. Классификация отзывов может позволить понять причины положительного и отрицательного восприятия продукта, чтобы впоследствии улучшить качество товаров и услуг. Например, поняв, что негативные эмоции клиентов часто связаны с качеством упаковки, компания может улучшить ее качество, а после запустить рекламную кампанию с посылом «Мы учли ваши отзывы».

Аналогичный анализ можно проводить и с обращениями пользователей в службу поддержки. Сообщения с негативными эмоциями получают высокий приоритет и обрабатываются быстрее. Таким клиентам можно автоматически предлагать какие-либо бонусы или скидки, что значительно улучшит их опыт взаимодействия с продуктом.

Еще одна область применения – это социальные сети. Зачастую именно там люди выражают свои эмоции по поводу новых рекламных кампаний и продуктов. Таким образом, бренд может мониторить комментарии и реакции пользователей в соцсетях и фиксировать рост эмоций: если много негативных реакций, то нужно оперативно скорректировать рекламное сообщение; если же много позитивных – это знак, что маркетинговая команда движется в правильном направлении. Все это поможет сильно снизить репутационные риски.

Кроме того, информацию об эмоциях пользователей можно использовать для настройки персонализированной рекламы. Учет эмоционального фона клиента делает такую рекламу более подходящей: например, пользователям с эмоцией «радость» можно показать предложения о развлечениях или путешествиях, а с эмоцией «грусть» – товары для отдыха или поднятия настроения.

Заключение

В ходе выполнения курсовой работы была разработана нейронная сеть для распознавания эмоций в текстах и проанализированы возможности ее практического применения в маркетинге

В рамках исследования была проанализирована предметная область, проведено исследование набора данных и сделана предобработка текстовых данных, была поставлена задача машинного обучения и определены целевые метрики, были реализованы и оптимизированы базовая SVM-модель и BiLSTM-модель на основе нейронных сетей. В конце были рассмотрены основные сценарии применения разработанной модели в маркетинге.

BiLSTM-модель показала отличное качество по всем ключевым метрикам. Итоговое значение accuracy и weighted f1-score составило 0,94, а значения ROC-AUC для всех классов находилось в диапазоне 0,996 – 0,999. Это говорит о высокой обобщающей способности модели и ее устойчивости к дисбалансу классов.

Полученная модель может быть использована в маркетинге при работе с данными пользователей: для автоматического анализа отзывов, улучшения работы службы поддержки, мониторинга соцсетей и улучшения персонализированной рекламы для пользователей.

В дальнейшем исследование можно продолжать, используя другие архитектуры моделей, например трансформеры (BERT и т.д.) или даже использовать большие языковые модели.

Список литературы

1. Дворников Сергей Викторович РАСПОЗНАВАНИЕ ЭМОЦИЙ В ТЕКСТОВОМ СООБЩЕНИИ // StudNet. 2021. №11. URL: <https://cyberleninka.ru/article/n/raspoznavaanie-emotsiy-v-tekstovom-soobschenii> (дата обращения: 16.12.2025).
2. Жан Макс Тапе Хабиб, Алексей Андреевич Погуда Сравнение методов анализа настроений глубокого обучения, включая LSTM и машинное обучение // Открытое образование. 2023. №4. URL: <https://cyberleninka.ru/article/n/sravnenie-metodov-analiza-nastroeniy-glubokogo-obucheniya-vklyuchaya-lstm-i-mashinnoe-obuchenie> (дата обращения: 16.12.2025).
3. О. У. Юлдашева, О. А. Погребова, А. Д. Артюнин ТЕХНОЛОГИИ ОБРАБОТКИ ЕСТЕСТВЕННОГО ЯЗЫКА В МАРКЕТИНГЕ: ОБЛАСТИ ПРИМЕНЕНИЯ И РЕШАЕМЫЕ ЗАДАЧИ // Российский журнал менеджмента. 2025. №2. URL: <https://cyberleninka.ru/article/n/tehnologii-obrabotki-estestvennogo-yazyka-v-marketinge-oblasti-primeneniya-i-reshaemye-zadachi> (дата обращения: 16.12.2025).
4. О. У. Юлдашева, Д. Е. Пирогов Становление концепции Data Driven маркетинга // Практический маркетинг. 2021. №11. URL: <https://cyberleninka.ru/article/n/stanovlenie-kontseptsii-data-driven-marketinga> (дата обращения: 18.12.2025).
5. Ajoke, Romoke and Lola, Femi and Samuel, Adebis Leveraging Natural Language Processing in Marketing // 2025
6. M. Grandini, E. Bagli, G. Visani Metrics for Multi-Class Classification: an Overview // 2020 URL: <https://arxiv.org/abs/2008.05756>
7. Hartmann, Jochen and Netzer, Oded Natural Language Processing in Marketing // Artificial Intelligence in Marketing. - Emerald Publishing Limited, 2023
8. C. Märtin, B. C. Bissinger, P. Asta Optimizing the digital customer journey—Improving user experience by exploiting emotions, personas and situations for

- individualized user interface adaptations // Journal of Consumer Behaviour. - 2023. - №22. - C. 1050-1061.
9. Yanying Mao, Qun Liu, Yu Zhang Sentiment analysis methods, applications, and challenges: A systematic literature review // Journal of King Saud University - Computer and Information Sciences. - 2024. - №36
 10. Xie, Jun and Chen, Bo and Gu, Xinglong and Liang, Fengmei and Xu, Xinying Self-Attention-Based BiLSTM Model for Short Text Fine-grained Sentiment Classification // IEEE Access. - 2019. - №7. - C. 1-1.

Приложение

Ссылка на открытый репозиторий с кодом:
https://github.com/avmaslakova/course_project_2026/blob/main/course_project.ipynb